


Prédiction spatiale : l'approche *Bayesian Data Fusion* (BDF)

P. Bogaert – UCL
Janvier 2018

Prédiction spatiale : définition

Fournir une information de la meilleure qualité possible sur une variable Z en un endroit x_0 à partir d'informations sur une (des) variable(s) Y mesurées en des endroits $\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_n$.



Prédiction spatiale : cas de figure

Ce qu'il faut prédire :

- Prédiction de variables **continues** vs variables catégorielles
- Prédictions **ponctuelles** vs agrégées sur des supports

Ce dont on dispose :

- Mesures **spatiales** vs spatio-temporelles
- Mesures **ponctuelles** vs **agrégées**
- Mesures univariées vs **multivariées**
- Mesures exactes vs **incertaines**

Prédiction spatiale: ce qui est souhaitable

Pour les input (informations):

- Souplesse pour intégrer des informations multiples
- Prise en compte d'une qualité variable des informations

Pour les output (prédictions) :

- Qualité optimale des prédictions
- Mesure de l'incertitude sur les prédictions
- Temps de calcul & complexité raisonnables

Prédiction spatiale : types de méthode

Méthodes linéaires :

- On accorde des poids aux mesures
- On prédit sur base d'une combinaison linéaire pondérée
- *Exemples* : distance inverse, krigeage, géographiquement pondérée, régression, splines, ...

Méthodes non linéaires :

- Tout le reste (réseaux de neurones, certaines variations du krigeage, BME/BDF, ...)

Prédiction spatiale : ce qu'on cherche

- Une expression pour la loi conditionnelle

$$\begin{array}{c} \text{inconnu} \quad \text{input } (y_0, \mathbf{y}) \\ \downarrow \quad \underbrace{\hspace{1.5cm}} \\ f(z_0 | y_0, y_1, \dots, y_n) \end{array}$$

- Un prédicteur ayant des propriétés « optimales »

$$\underline{ex} : E[z_0 | y_0, y_1, \dots, y_n]$$

- Une mesure de la qualité de prédiction

$$\underline{ex} : Var[z_0 | y_0, y_1, \dots, y_n]$$

Prédiction spatiale : ce que nous faisons (BDF)

- Choisir une distribution conjointe de départ

$$f(\mathbf{z}) = f(z_0, z_1, \dots, z_n)$$

- Recoder l'information apportée par les y_i 's

$$(\hat{y}_i, \hat{z}_i) \rightarrow f(z_i | y_i)$$

- Intégrer l'information pour la distribution conditionnelle

$$f(z_0 | \mathbf{y}) = \frac{1}{B} \frac{f(z_0 | y_0)}{f(z_0)} \int_{\mathbb{R}} \dots \int_{\mathbb{R}} f(\mathbf{z}) \prod_{i=1}^n \frac{f(z_i | y_i)}{f(z_i)} dz_1 \dots dz_n$$

Prédiction spatiale : ce que nous faisons

Avantages :

- Permet d'incorporer des y_i 's arbitraires via les $f(z_i|y_i)$'s
- Peu d'hypothèses de modélisation pour ces $f(z_i|y_i)$'s
- Prise en compte de l'incertitude des input via les $f(z_i|y_i)$'s
- Plusieurs input $y_{i,1}, \dots, y_{i,m}$ aux mêmes endroits sont possibles
- Compatible avec des choix classiques pour $f(\mathbf{z})$

Désavantages :

- Basé sur une hypothèse d'indépendance conditionnelle (pas forte)
- Coûteux dans sa formulation la plus générale (intégrales multiples)

Prédiction spatiale : ce que nous faisons


Simplifications :

- Se réduit à une formule simple si les inputs sont y_0, z_1, \dots, z_n


$$f(z_0 | \underbrace{y_0, z_1, \dots, z_n}_{\text{input } (y_0, \mathbf{z})}) = \frac{1}{B} \frac{f(z_0 | y_0)}{f(z_0)} \underbrace{f(z_0 | \mathbf{z})}_{\substack{\text{distribution conditionnelle} \\ \text{« classique » (krigeage)}}}$$

- Se réduit à une prédiction linéaire si $f(\mathbf{z})$ et $f(z_i | y_i)$'s sont gaussiens (kriging with measurement errors)

Prédiction spatiale : une illustration (water table depth)




Rivers network and sampled water table depth




Digital Elevation Model

Prédiction spatiale : une illustration (water table depth)




Différences entre profondeur de la nappe $Z(\mathbf{x})$ et $DEM(\mathbf{x})$
en fonction de la distance à la rivière $d_{DEM}(\mathbf{x})$

Prédiction spatiale : une illustration (water table depth)



Carte de la nappe par cokrigage



Carte de la nappe par BDF